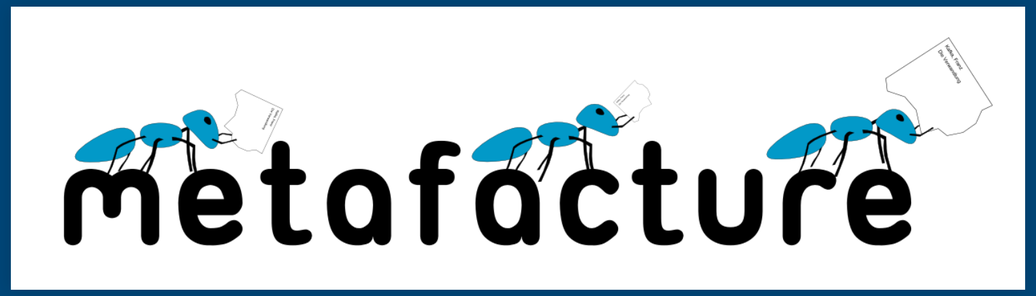

Metadatenworkflows mit Metafacture erstellen und verwalten

Fabian Steeg & Tobias Bülte

Offene Infrastruktur, Hochschulbibliothekszentrum NRW (hbz)

WWW,
Mai 2022

https://slides.lobid.org/2022-05-metafacture-workshop/ (PDF)

Agenda

1. Einführung & Kontext
2. Workflows
3. Transformieren
4. Analysieren
5. Zusammenführen
6. Ausblick, Fragen & Diskussion

1. Kontext: Datentransformation

Anwendungsszenarien

Anwendungsszenarien

Datenanalyse, z.B. Feldabdeckung im Katalog

Anwendungsszenarien

Datenanalyse, z.B. Feldabdeckung im Katalog

Datenaufbereitung, z.B. zur Visualisierung mit Kibana

Anwendungsszenarien

Datenanalyse, z.B. Feldabdeckung im Katalog

Datenaufbereitung, z.B. zur Visualisierung mit Kibana

Datenanreicherung, z.B. Ergänzung von Daten aus Wikidata

T

Anwendungsszenarien

Datenanalyse, z.B. Feldabdeckung im Katalog

Datenaufbereitung, z.B. zur Visualisierung mit Kibana

Datenanreicherung, z.B. Ergänzung von Daten aus Wikidata

Datenaggregation aus unterschiedlichen Quellen, z.B. OERSI

T

Anwendungsszenarien

Datenanalyse, z.B. Feldabdeckung im Katalog

Datenaufbereitung, z.B. zur Visualisierung mit Kibana

Datenanreicherung, z.B. Ergänzung von Daten aus Wikidata

Datenaggregation aus unterschiedlichen Quellen, z.B. OERSI

Systemmigration, z.B. nach Alma oder Folio

Wo wir Metafacture nutzen

Wo wir Metafacture nutzen

Transformation der Daten des Verbundkatalogs für die Indexierung (lobid.org)

Wo wir Metafacture nutzen

Transformation der Daten des Verbundkatalogs für die Indexierung (lobid.org)

Metadaten aus verschiedenen Quellen im OER Suchindex aggregieren (OERSI)

Wo wir Metafacture nutzen

Transformation der Daten des Verbundkatalogs für die Indexierung (lobid.org)

Metadaten aus verschiedenen Quellen im OER Suchindex aggregieren (OERSI)

Transformation der Daten der Rheinland-Pfälzischen Bibliographie

T

Nur ein kleiner Teil

Nur ein kleiner Teil

Sehr vielseitiges Tool mit vielen Anwendungsmöglichkeiten, Formaten, Modulen

Nur ein kleiner Teil

Sehr vielseitiges Tool mit vielen Anwendungsmöglichkeiten, Formaten, Modulen

Wir nutzen davon nur einen kleinen Teil, eben für unsere Formate und Anwendungsfälle

Nur ein kleiner Teil

Sehr vielseitiges Tool mit vielen Anwendungsmöglichkeiten, Formaten, Modulen

Wir nutzen davon nur einen kleinen Teil, eben für unsere Formate und Anwendungsfälle

Wir versuchen euch hier einen möglichst breiten Überblick zu geben über Konzepte und Möglichkeiten

Annahmen

Annahmen

Transformationen von Metadaten gehören zum täglichen Geschäft wissenschaftlicher Bibliotheken.

Annahmen

Transformationen von Metadaten gehören zum täglichen Geschäft wissenschaftlicher Bibliotheken.

Es gibt viele unterschiedliche Methoden, die meist Programmierkenntnisse voraussetzen.

T

Annahmen

Transformationen von Metadaten gehören zum täglichen Geschäft wissenschaftlicher Bibliotheken.

Es gibt viele unterschiedliche Methoden, die meist Programmierkenntnisse voraussetzen.

Datentransformationen werden meist im Zusammenspiel von Fachabteilungen & IT umgesetzt, verbunden mit größerem Kommunikationsaufwand.

T

Annahmen

Transformationen von Metadaten gehören zum täglichen Geschäft wissenschaftlicher Bibliotheken.

Es gibt viele unterschiedliche Methoden, die meist Programmierkenntnisse voraussetzen.

Datentransformationen werden meist im Zusammenspiel von Fachabteilungen & IT umgesetzt, verbunden mit größerem Kommunikationsaufwand.

Bereits existierende, von anderen entwickelte Transformationsprozesse können nur bedingt entdeckt und nachgenutzt werden.

Das heißt:

Das heißt:

Es gibt großes Potential, eine immer wiederkehrende Arbeit zugänglicher, kollaborativer und effizienter zu gestalten.

Übergeordnete Ziele

Übergeordnete Ziele

Ermächtigung der Fachebene zur Konfiguration von Datentransformationen

Übergeordnete Ziele

Ermächtigung der Fachebene zur Konfiguration von Datentransformationen

Förderung von Praktiken zum Teilen und Auffinden von Transformationsprozessen

Was ist Metafacture?

Was ist Metafacture?

Ein vielseitiges Werkzeug zur Verarbeitung von semi-strukturierten Daten mit dem Fokus auf Bibliotheksdaten

Was ist Metafacture?

Ein vielseitiges Werkzeug zur Verarbeitung von semi-strukturierten Daten mit dem Fokus auf Bibliotheksdaten

nutzbar als Kommandozeilentool, als Java/JVM library,

Was ist Metafacture?

Ein vielseitiges Werkzeug zur Verarbeitung von semi-strukturierten Daten mit dem Fokus auf Bibliotheksdaten

nutzbar als Kommandozeilentool, als Java/JVM library,

für Batch-Verarbeitung oder on-the-fly

Was ist Metafacture?

Ein vielseitiges Werkzeug zur Verarbeitung von semi-strukturierten Daten mit dem Fokus auf Bibliotheksdaten

nutzbar als Kommandozeilentool, als Java/JVM library,

für Batch-Verarbeitung oder on-the-fly

offenes Framework: Weiterentwicklung, Wiederverwendung und Austausch (von einzelnen Modulen und ganzen Workflows)

Metafacture-Historie

Metafacture-Historie

2011: Start der Entwicklung durch DNB im Rahmen von Culturegraph; damals schon Austausch mit dem hbz

Metafacture-Historie

2011: Start der Entwicklung durch DNB im Rahmen von Culturegraph; damals schon Austausch mit dem hbz

2013: Umzug auf GitHub, Open-Source-Projekt geworden

Metafacture-Historie

2011: Start der Entwicklung durch DNB im Rahmen von Culturegraph; damals schon Austausch mit dem hbz

2013: Umzug auf GitHub, Open-Source-Projekt geworden

2019: Mit der Zeit immer weniger DNB-Ressourcen für Metafacture, hbz wird Maintainer

Metafacture-Historie

2011: Start der Entwicklung durch DNB im Rahmen von Culturegraph; damals schon Austausch mit dem hbz

2013: Umzug auf GitHub, Open-Source-Projekt geworden

2019: Mit der Zeit immer weniger DNB-Ressourcen für Metafacture, hbz wird Maintainer

2019: Start von Metafacture Fix

Metafacture-Historie

2011: Start der Entwicklung durch DNB im Rahmen von Culturegraph; damals schon Austausch mit dem hbz

2013: Umzug auf GitHub, Open-Source-Projekt geworden

2019: Mit der Zeit immer weniger DNB-Ressourcen für Metafacture, hbz wird Maintainer

2019: Start von Metafacture Fix

2021: Start von Metafacture Playground

Wie Metafacture funktioniert

Wie Metafacture funktioniert

Grundidee: Daten fließen durch mehrere Module:

→ read → decode → transform → encode → write →

Wie Metafacture funktioniert

Grundidee: Daten fließen durch mehrere Module:
→ read → decode → transform → encode → write →

Jedes Modul erwartet Input eines bestimmten Typs und erzeugt Output eines bestimmten Typs

Wie Metafacture funktioniert

Grundidee: Daten fließen durch mehrere Module:
→ read → decode → transform → encode → write →

Jedes Modul erwartet Input eines bestimmten Typs und erzeugt Output eines bestimmten Typs

Verschiedene Formate werden unterstützt (z.B. PICA, MARC), erweiterbares Framework für eigene Formate

Wie Metafacture funktioniert

Grundidee: Daten fließen durch mehrere Module:
→ read → decode → transform → encode → write →

Jedes Modul erwartet Input eines bestimmten Typs und erzeugt Output eines bestimmten Typs

Verschiedene Formate werden unterstützt (z.B. PICA, MARC), erweiterbares Framework für eigene Formate

Durch Kombination einzelner Module, durch die unsere Daten fließen, bauen wir den Workflow

2. Workflows

Ein Workflow

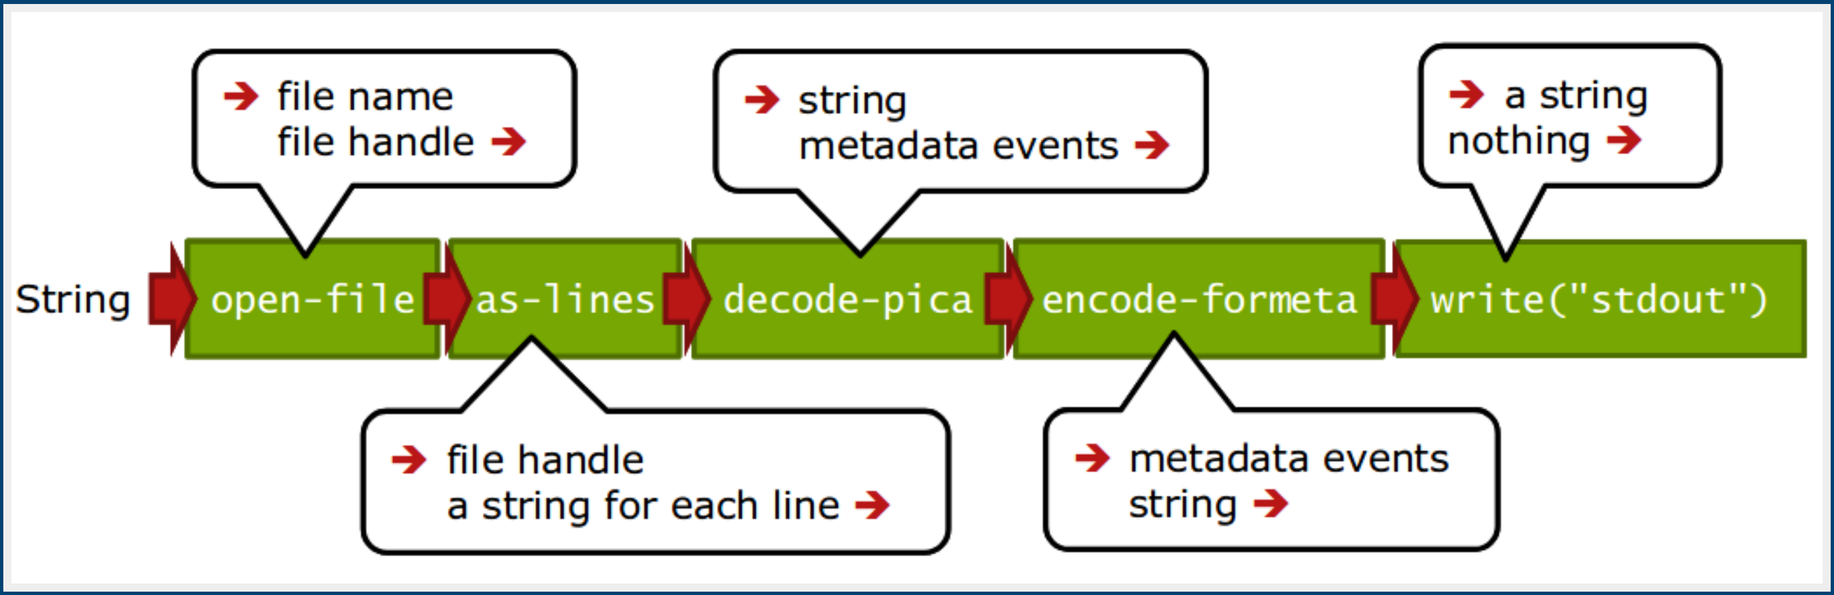

Aus: Christoph Böhme, http://swib.org/swib13/slides/boehme_swib13_131.pdf

Workflows konfigurieren und ausführen

Workflows konfigurieren und ausführen

Workflows können in Flux (einer speziellen Konfigurationssprache) oder mit Java (typsicher über Java Generics) bearbeitet werden

Workflows konfigurieren und ausführen

Workflows können in Flux (einer speziellen Konfigurationssprache) oder mit Java (typsicher über Java Generics) bearbeitet werden

Flux-Workflows können in einem Texteditor editiert und auf der Kommandozeile ausgeführt werden, Java-Workflows funktionieren wie andere Java-Komponenten

Workflows konfigurieren und ausführen

Workflows können in Flux (einer speziellen Konfigurationssprache) oder mit Java (typsicher über Java Generics) bearbeitet werden

Flux-Workflows können in einem Texteditor editiert und auf der Kommandozeile ausgeführt werden, Java-Workflows funktionieren wie andere Java-Komponenten

Der Workshop führt in die Nutzung der Flux-Workflows ein, zum Ausführen verwenden wir den Metafacture Playground

Metafacture Playground

Metafacture Playground

Webbasierte Oberfläche zum Ausprobieren und Austauschen von Workflows

Metafacture Playground

Webbasierte Oberfläche zum Ausprobieren und Austauschen von Workflows

Ziel: Einstiegshürde für Metafacture senken, unserer Erfahrung nach ein zentrales Problem bei der Metafacture-Nutzung

Metafacture Playground

Webbasierte Oberfläche zum Ausprobieren und Austauschen von Workflows

Ziel: Einstiegshürde für Metafacture senken, unserer Erfahrung nach ein zentrales Problem bei der Metafacture-Nutzung

Für Entwicklung, Dokumentation, Tutorials, Workshops

Metafacture Playground

Webbasierte Oberfläche zum Ausprobieren und Austauschen von Workflows

Ziel: Einstiegshürde für Metafacture senken, unserer Erfahrung nach ein zentrales Problem bei der Metafacture-Nutzung

Für Entwicklung, Dokumentation, Tutorials, Workshops

https://metafacture.org/playground

Wie funktioniert das in der Praxis? Lasst uns das gemeinsam ausprobieren.

(die folgenden Screenshots verlinken die Beispiele zum Ausprobieren im Playground)

Load Examples | Clear | Process | Share | Import Workflow | Export Workflow

Data

```
001@ a501-2001A 01100:15-10-94001B 09999:12-06-06t16:10:17.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aag003@ 048214
001@ 01a5001A 01140:08-12-99001B 09999:05-01-08t22:57:29.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aa003@ 095809056
001@ a501001A 01140:19-02-03001B 09999:19-06-11t01:20:13.000001D 09999:26-04-03001U 0utf8001X 00002@ 0Aal003@ 036180954
001@ a501-3001A 01240:01-08-95001B 09999:24-09-10t17:42:20.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Af003@ 094518400
001@ 01-2a5001A 01239:18-08-11001B 09999:05-09-11t23:31:44.000001D 01240:30-08-11001U 0utf8001X 00002@ 0Af003@ 010144117
```

Flux

```
PG_DATA | as-lines | decode-pica | encode-json | print ;
```

Fix | Morph

Result

{"001@":{"a":"5","0":"1-2"},"001A":{"0":"1100:15-10-94"},"001B":{"0":"9999:12-06-06","t":"16:10:17.000"},"001D":{"0":"9999:99-99-99"},"001U":{"0":"utf8"},"001X":{"0":"0"},"002@":{"0":"Aag"},"003@":{"0":"482147350"},"006U":{"0":"94,P05"},"007E":{"0":"U 70.16407"},"007I":{"S":"o","0":"74057548"},"011@":{"a":"1970"},"017A":{"a":"rh"},"021A":{"a":"Die @Berufsfreiheit der Arbeitnehmer und ihre Ausgestaltung in völkerrechtlichen Verträgen","d":"Eine Grundrechtsbetrachtg"},"028A":{"9":"106884905","7":"Tn3","A":"gnd","0":"106884905","a":"Projahn","d":"Horst D."},"033A":{"p":"Würzburg"},"034D":{"a":"XXXVIII, 165 S."},"034I":{"a":"8"},"037C":{"a":"Würzburg, Jur. F., Diss. v. 7. Aug. 1970"}}

Übung: Formatierung & Optionen

Playground-Beispiel anpassen:

```
PG_DATA
| as-lines
| decode-pica
| encode-json(prettyPrinting = "true")
| print
;
```

Load Examples | Clear | Process | Share | Import Workflow | Export Workflow

Data

```
001@ a501-2001A 01100:15-10-94001B 09999:12-06-06t16:10:17.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aag003@ 048214
001@ 01a5001A 01140:08-12-99001B 09999:05-01-08t22:57:29.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aa003@ 095809056
001@ a501001A 01140:19-02-03001B 09999:19-06-11t01:20:13.000001D 09999:26-04-03001U 0utf8001X 00002@ 0Aal003@ 036180955
001@ a501-3001A 01240:01-08-95001B 09999:24-09-10t17:42:20.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Af003@ 0945184(
001@ 01-2a5001A 01239:18-08-11001B 09999:05-09-11t23:31:44.000001D 01240:30-08-11001U 0utf8001X 00002@ 0Af003@ 0101441
```

Flux

```
PG_DATA
| as-lines
| decode-pica
| encode-json(prettyPrinting = "true")
| print
;
```

Fix | Morph

Result


```
{
 "001@":{
  "a":"5",
  "0":"1-2"
 },
 "001A":{
  "0":"1100:15-10-94"
 },
```

Dokumentation

Dokumentation

Was für Module gibt es? Was machen die?

Dokumentation

Was für Module gibt es? Was machen die?

https://github.com/metafacture/metafacture-documentation/blob/master/flux-commands.md

Dokumentation

Was für Module gibt es? Was machen die?

https://github.com/metafacture/metafacture-documentation/blob/master/flux-commands.md

z.B. statt JSON als "Formeta" ausgeben, formatiert

encode-formeta(style="multiline")

```
'482147350' {
        '001@' {
                 'a': '5',
                 '0': '1-2'
        },
        '001A' {
                 '0': '1100:15-10-94'
        },
        '001B' {
                 '0': '9999:12-06-06',
                 't': '16:10:17.000'
        },
        '001D' {
                 '0': '9999:99-99-99'
        },
        '001U' {
```

https://github.com/hbz/metafacture-flux-examples/tree/master/sample1

3. Transformieren

Transformieren

Transformieren

Manipulation von Feldnamen und -werten; filtern, kombinieren, trennen, normalisieren etc.

Transformieren

Manipulation von Feldnamen und -werten; filtern, kombinieren, trennen, normalisieren etc.

Änderung der Struktur und Hierarchie eines Records etc.

Transformieren

Manipulation von Feldnamen und -werten; filtern, kombinieren, trennen, normalisieren etc.

Änderung der Struktur und Hierarchie eines Records etc.

Feldwerte aus Lookup-Tabellen in externen Dateien (z.B. Freitextfelder -> kontrollierte Vokabulare)

T

Transformationsmodul

Transformationsmodul

Morph: XML-basiert, Feld- / Metadaten-Event-Ebene

Transformationsmodul

Morph: XML-basiert, Feld- / Metadaten-Event-Ebene

Fix: eigene, Catmandu-Fix-artige Sprache, Record-basiert

Metafacture Fix: Ziele

Metafacture Fix: Ziele

Erleichterung der Transformationskonfiguration

Metafacture Fix: Ziele

Erleichterung der Transformationskonfiguration

Anknüpfung an existierende Konfigurationssprache aus Catmandu (mittelfristiges Ziel: Standardisierung, s. https://github.com/elag/FIG)

Metafacture Fix: Ziele

Erleichterung der Transformationskonfiguration

Anknüpfung an existierende Konfigurationssprache aus Catmandu (mittelfristiges Ziel: Standardisierung, s. https://github.com/elag/FIG)

Vergrößerung der Zielgruppe um Bibliothekar:innen und andere Metadatenfachleute (bei uns z.B. in OERSI, erster Anwendungsfall und Entwicklungsbegleitung zu Fix)

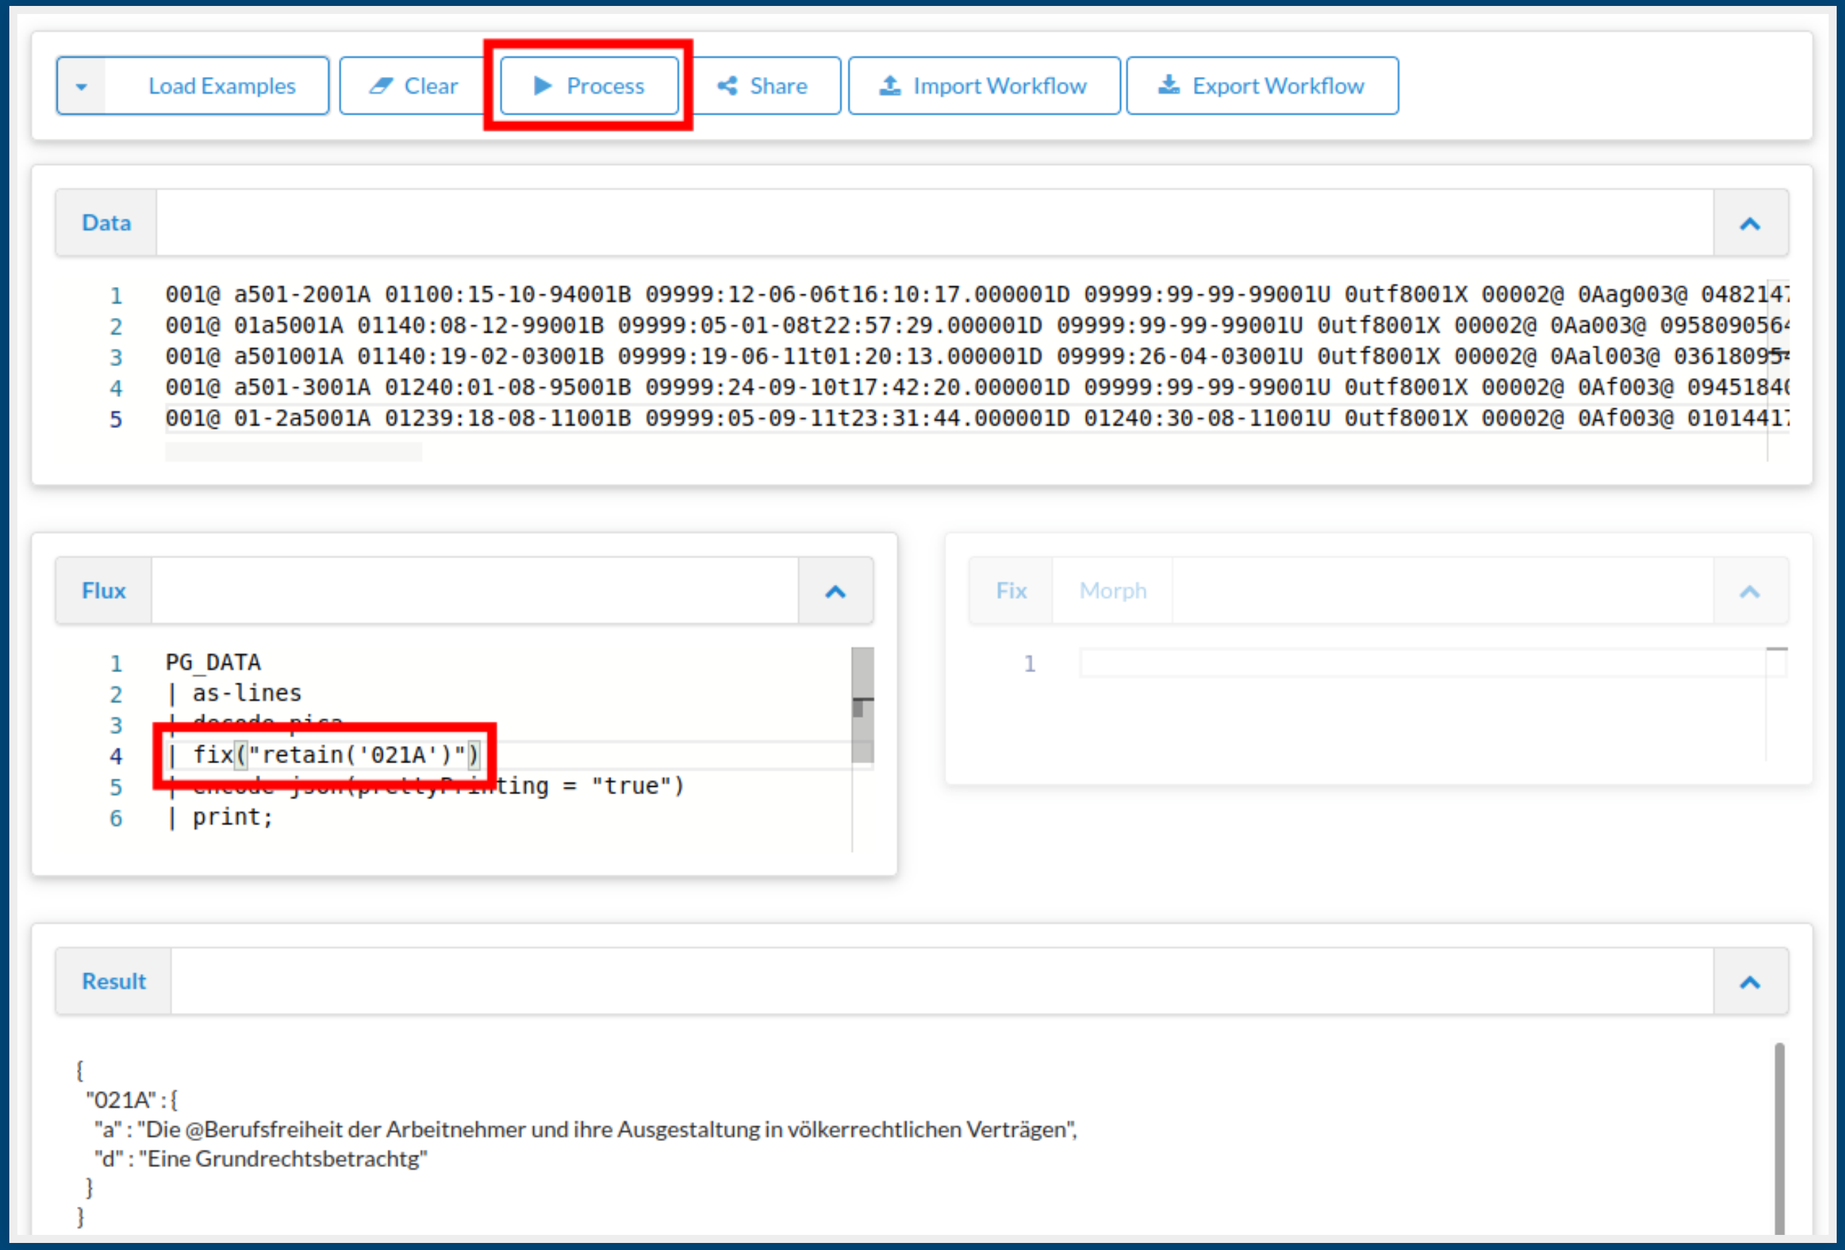
Load Examples
Clear
Process
Share
Import Workflow
Export Workflow
Data
001@ a501-2001A 01100:15-10-94001B 09999:12-06-06t16:10:17.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aag003@ 048214
001@ 01a5001A 01140:08-12-99001B 09999:05-01-08t22:57:29.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aa003@ 095809056
001@ a501001A 01140:19-02-03001B 09999:19-06-11t01:20:13.000001D 09999:26-04-03001U 0utf8001X 00002@ 0Aal003@ 036180955
001@ a501-3001A 01240:01-08-95001B 09999:24-09-10t17:42:20.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Af003@ 0945184
001@ 01-2a5001A 01239:18-08-11001B 09999:05-09-11t23:31:44.000001D 01240:30-08-11001U 0utf8001X 00002@ 0Af003@ 0101441
Flux
PG_DATA
| as-lines
| fix("retain('021A')")
| print;
Fix
Morph
Result
{
"021A" : {
"a" : "Die @Berufsfreiheit der Arbeitnehmer und ihre Ausgestaltung in völkerrechtlichen Verträgen",
"d" : "Eine Grundrechtsbetrachtg"
}
}

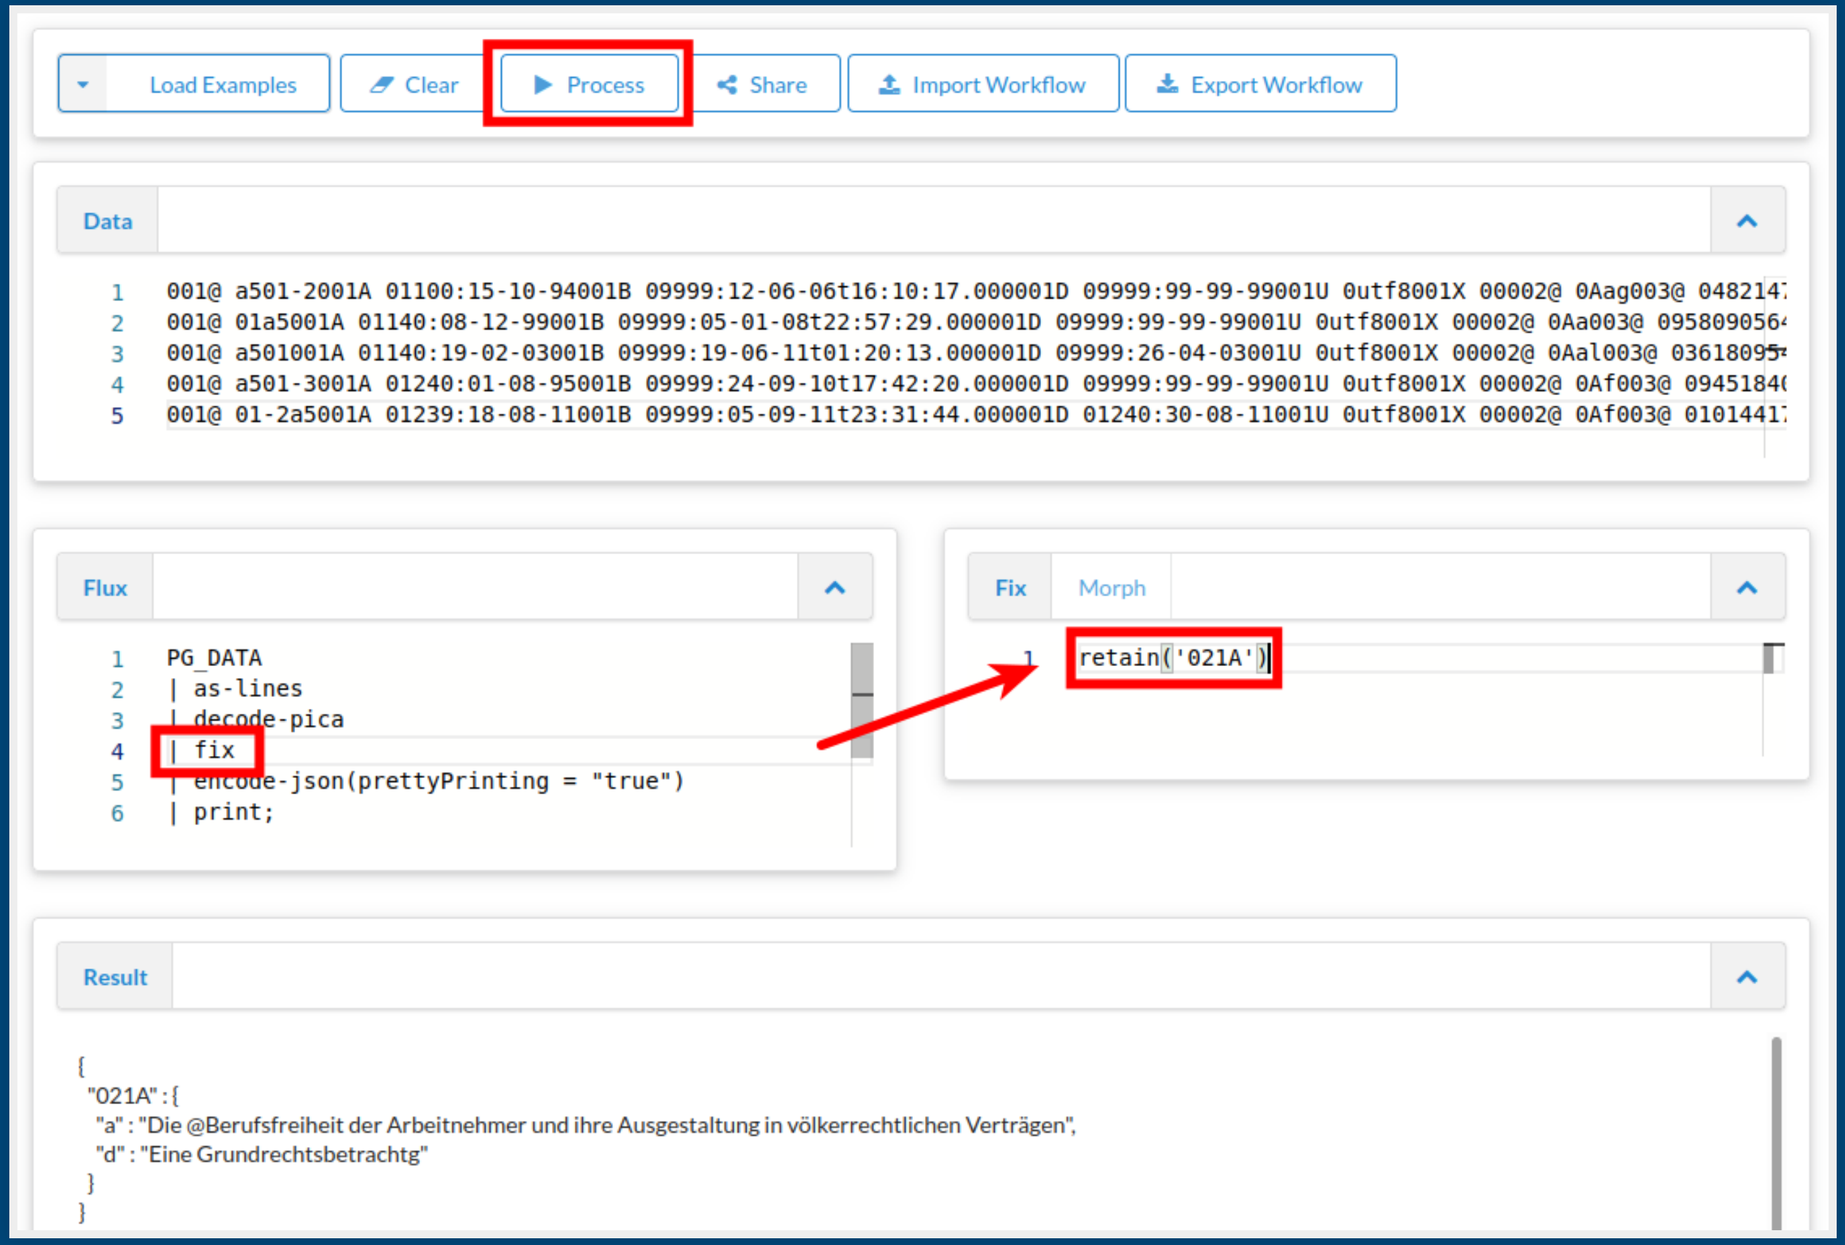
Load Examples
Clear
Process
Share
Import Workflow
Export Workflow
Data
001@ a501-2001A 01100:15-10-94001B 09999:12-06-06t16:10:17.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aag003@ 048214
001@ 01a5001A 01140:08-12-99001B 09999:05-01-08t22:57:29.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aa003@ 095809056
001@ a501001A 01140:19-02-03001B 09999:19-06-11t01:20:13.000001D 09999:26-04-03001U 0utf8001X 00002@ 0Aal003@ 03618095
001@ a501-3001A 01240:01-08-95001B 09999:24-09-10t17:42:20.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Af003@ 0945184
001@ 01-2a5001A 01239:18-08-11001B 09999:05-09-11t23:31:44.000001D 01240:30-08-11001U 0utf8001X 00002@ 0Af003@ 0101441
Flux
PG_DATA
| as-lines
| decode-pica
| fix
| encode-json(prettyPrinting = "true")
| print;
Fix
Morph
retain('021A')
Result
{
"021A" : {
"a" : "Die @Berufsfreiheit der Arbeitnehmer und ihre Ausgestaltung in völkerrechtlichen Verträgen",
"d" : "Eine Grundrechtsbetrachtg"
}
}

Metafacture Fix: Pfade

Metafacture Fix: Pfade

Um die verschiedenen Elemente und Felder für die Transformation anzuwählen, muss man ihre Pfade angeben

Metafacture Fix: Pfade

Um die verschiedenen Elemente und Felder für die Transformation anzuwählen, muss man ihre Pfade angeben

Einfache Elemente der obersten Ebene / Felder: `id`

Metafacture Fix: Pfade

Um die verschiedenen Elemente und Felder für die Transformation anzuwählen, muss man ihre Pfade angeben

Einfache Elemente der obersten Ebene / Felder: `id`

Elemente auf einer unteren Ebene / Unterfelder: `title.subtitle`

T

Metafacture Fix: Pfade

Um die verschiedenen Elemente und Felder für die Transformation anzuwählen, muss man ihre Pfade angeben

Einfache Elemente der obersten Ebene / Felder: `id`

Elemente auf einer unteren Ebene / Unterfelder: `title.subtitle`

Wiederholte Felder werden als Listen mit Index-Nummer angegeben: `creator.1.name.firstName`

T

Übung

Übung

z.B. Titel, Verlag, Erscheinungsort und -jahr aus den PICA-Feldern 021A.a, 033A.n, 033A.p, 011@.n verwenden

Übung

z.B. Titel, Verlag, Erscheinungsort und -jahr aus den PICA-Feldern 021A.a, 033A.n, 033A.p, 011@.n verwenden

Verlag und Erscheinungsort sollen in einem neuen Feld kombiniert werden

Übung

z.B. Titel, Verlag, Erscheinungsort und -jahr aus den PICA-Feldern 021A.a, 033A.n, 033A.p, 011@.n verwenden

Verlag und Erscheinungsort sollen in einem neuen Feld kombiniert werden

Als Feldnamen wollen wir sprechende, nicht-numerische Bezeichnungen haben

Übung

z.B. Titel, Verlag, Erscheinungsort und -jahr aus den PICA-Feldern 021A.a, 033A.n, 033A.p, 011@.n verwenden

Verlag und Erscheinungsort sollen in einem neuen Feld kombiniert werden

Als Feldnamen wollen wir sprechende, nicht-numerische Bezeichnungen haben

z.B. mit move_field, paste, retain, s. Dokumentation

move_field, paste, retain

move_field, paste, retain

```
1{a: Faust, b {n: Goethe, v: JW}, c: Weimar}
2{a: Räuber, b {n: Schiller, v: F}, c: Weimar}
```

move_field, paste, retain

```
1{a: Faust, b {n: Goethe, v: JW}, c: Weimar}
2{a: Räuber, b {n: Schiller, v: F}, c: Weimar}
```

```
move_field(a, title)
paste(author, b.v, b.n, '~aus', c)
retain(title, author)
```

move_field, paste, retain

```
1{a: Faust, b {n: Goethe, v: JW}, c: Weimar}
2{a: Räuber, b {n: Schiller, v: F}, c: Weimar}
```

```
move_field(a, title)
paste(author, b.v, b.n, '~aus', c)
retain(title, author)
```

```
{"title":"Faust", "author":"JW Goethe aus Weimar"}
{"title":"Räuber", "author":"F Schiller aus Weimar"}
```

Beispiel im Playground

Load Examples | Clear | Process | Share | Import Workflow | Export Workflow

Data

```
001@ 01a5001A 01140:08-12-99001B 09999:05-01-08t22:57:29.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aa003@ 0958090564
001@ a501001A 01140:19-02-03001B 09999:19-06-11t01:20:13.000001D 09999:26-04-03001U 0utf8001X 00002@ 0Aal003@ 0361809547
001@ 02a5001A 01200:24-11-77001B 09999:16-01-08t01:01:54.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aan003@ 0780510147
001@ a501-2001A 01140:28-06-99001B 09999:17-04-11t14:40:50.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aa003@ 0956745
001@ 01a5001A 09999:08-03-02001B 09999:12-03-04t11:47:27.000001D 09999:08-03-02001U 0utf8001X 00002@ 0Aal003@ 0576121447
```

Flux

```
PG_DATA
| as-lines
| decode-pica
| fix
| encode-json(prettyPrinting = "true")
| print
;
```

Fix | Morph

```
move_field('021A.a', 'Title')
move_field('011@.a', Year)
paste('Publisher', '033A.n', '~: ', '033A.p')
retain(Title, Year, Publisher)
```

Result


```
{
 "Title" : "Zukunft Bildung",
 "Year" : "1999",
 "Publisher" : "Polit. Akad. :  Wien"
}
```

Lookup

Lookup

"Feldwerte aus Lookup-Tabellen in externen Dateien (z.B. Freitextfelder -> kontrollierte Vokabulare)"

Übung

Übung

Feld 002@.0 → dcterms:format

Übung

Feld 002@.0 → dcterms:format

In 002@.0, Position 1, A: print, B: audiovisual, O: online

Übung

Feld 002@.0 → dcterms:format

In 002@.0, Position 1, A: print, B: audiovisual, O: online

z.B. mit copy_field, substring, lookup, retain, s. Dokumentation

Flux

```
PG_DATA
| as-lines
| decode-pica
| fix
| encode-json(prettyPrinting = "true")
| print;
```

Fix | Morph

```
copy_field('002@.0', 'dcterms:format')
substring('dcterms:format', '0', '1')
lookup('dcterms:format', A: print, B: audiovisual, O: online)
retain('002@', 'dcterms:format')
```

Result


```
{
 "002@" : {
  "0" : "Aa"
 },
 "dcterms:format" : "print"
}
{
 "002@" : {
  "0" : "Aal"
 },
 "dcterms:format" : "print"
}
```

Export & Import

Export & Import

Workflow kann zur lokalen Ausführung aus dem Playground exportiert werden (Dateien-Download)

Export & Import

Workflow kann zur lokalen Ausführung aus dem Playground exportiert werden (Dateien-Download)

Flux-, Fix- und Daten-Datei können lokal bearbeitet und per Kommandozeile ausgeführt werden

Export & Import

Workflow kann zur lokalen Ausführung aus dem Playground exportiert werden (Dateien-Download)

Flux-, Fix- und Daten-Datei können lokal bearbeitet und per Kommandozeile ausgeführt werden

Dateien können dann auch wieder in den Playground importiert werden (Dateien-Upload)

Export & Import

Workflow kann zur lokalen Ausführung aus dem Playground exportiert werden (Dateien-Download)

Flux-, Fix- und Daten-Datei können lokal bearbeitet und per Kommandozeile ausgeführt werden

Dateien können dann auch wieder in den Playground importiert werden (Dateien-Upload)

https://github.com/metafacture/metafacture-fix/releases

sample3x Lookup fields | Clear | Process | Share | Import Workflow | Export Workflow

Data

Flux

```
1  PG_DATA
2  | as-lines
3  | decode-pica
4  | fix
5  | encode-json(prettyPrinting="true")
6  | print;
```

Fix | Morph

```
1  copy_field('002@.0', 'dcterms:format')
2  substring('dcterms:format', '0', '1')
3  lookup('dcterms:format', A: print, B: audiovisual, O: online)
4  retain('002@', 'dcterms:format')
```

Rückschau

Rückschau

Workflows mit Flux

Rückschau

Workflows mit Flux

Transformationen mit Fix

Rückschau

Workflows mit Flux

Transformationen mit Fix

Playground, Export, Import

4. Analysieren

stream-to-triples

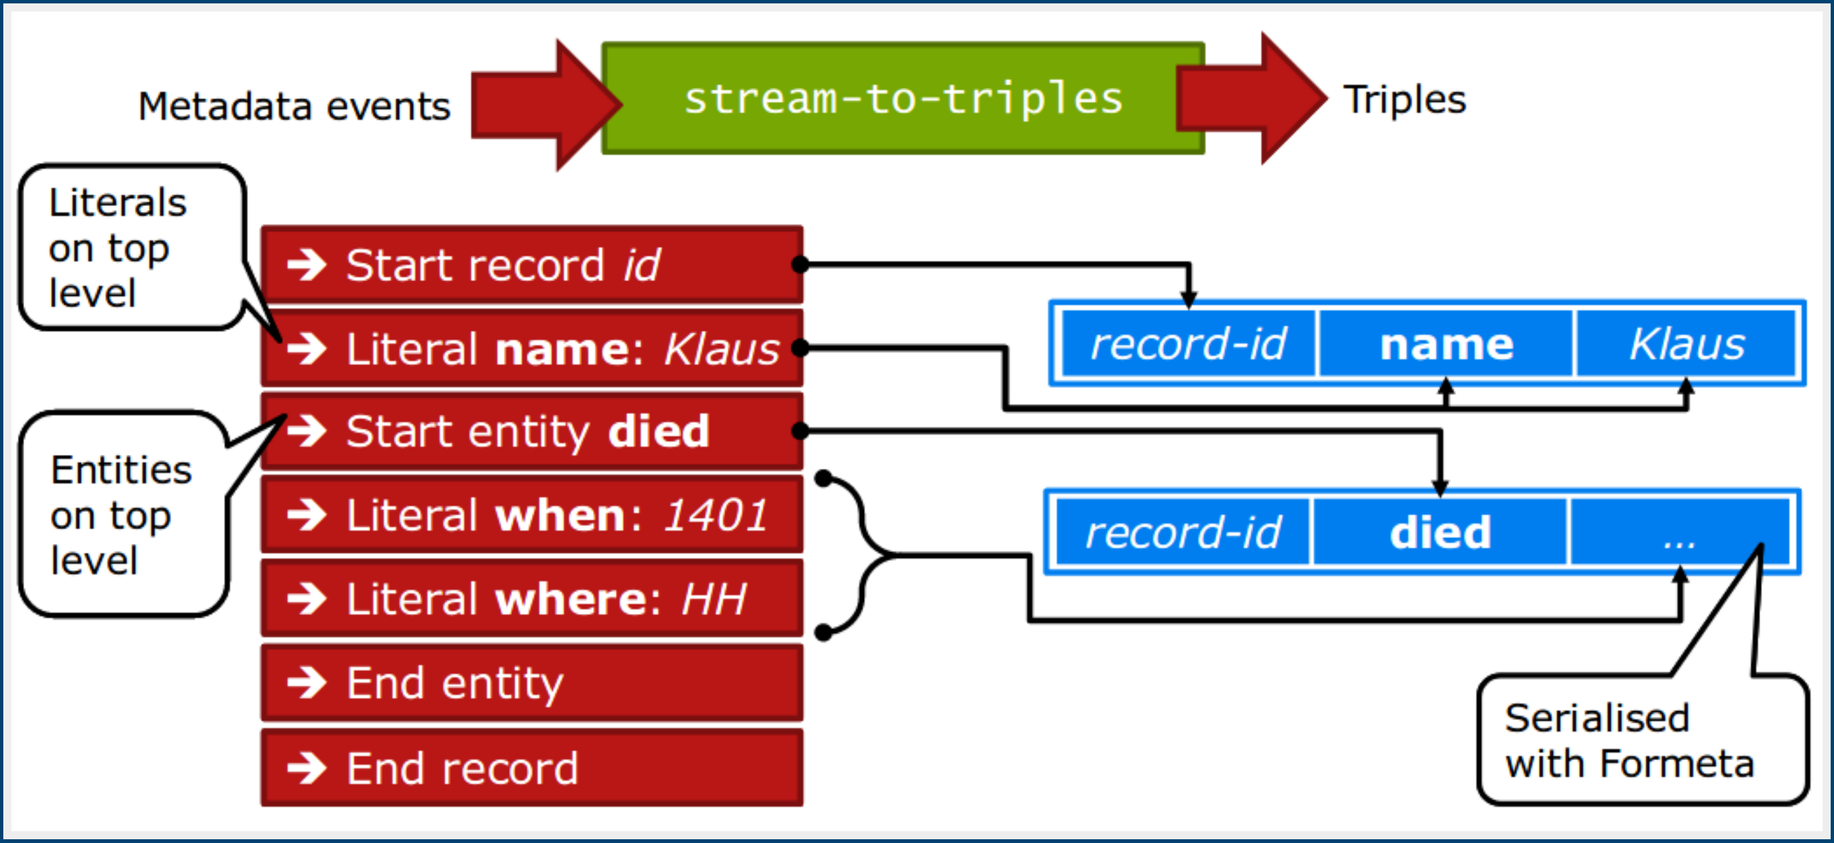

Source: Christoph Böhme, http://swib.org/swib13/slides/boehme_swib13_131.pdf

count-triples

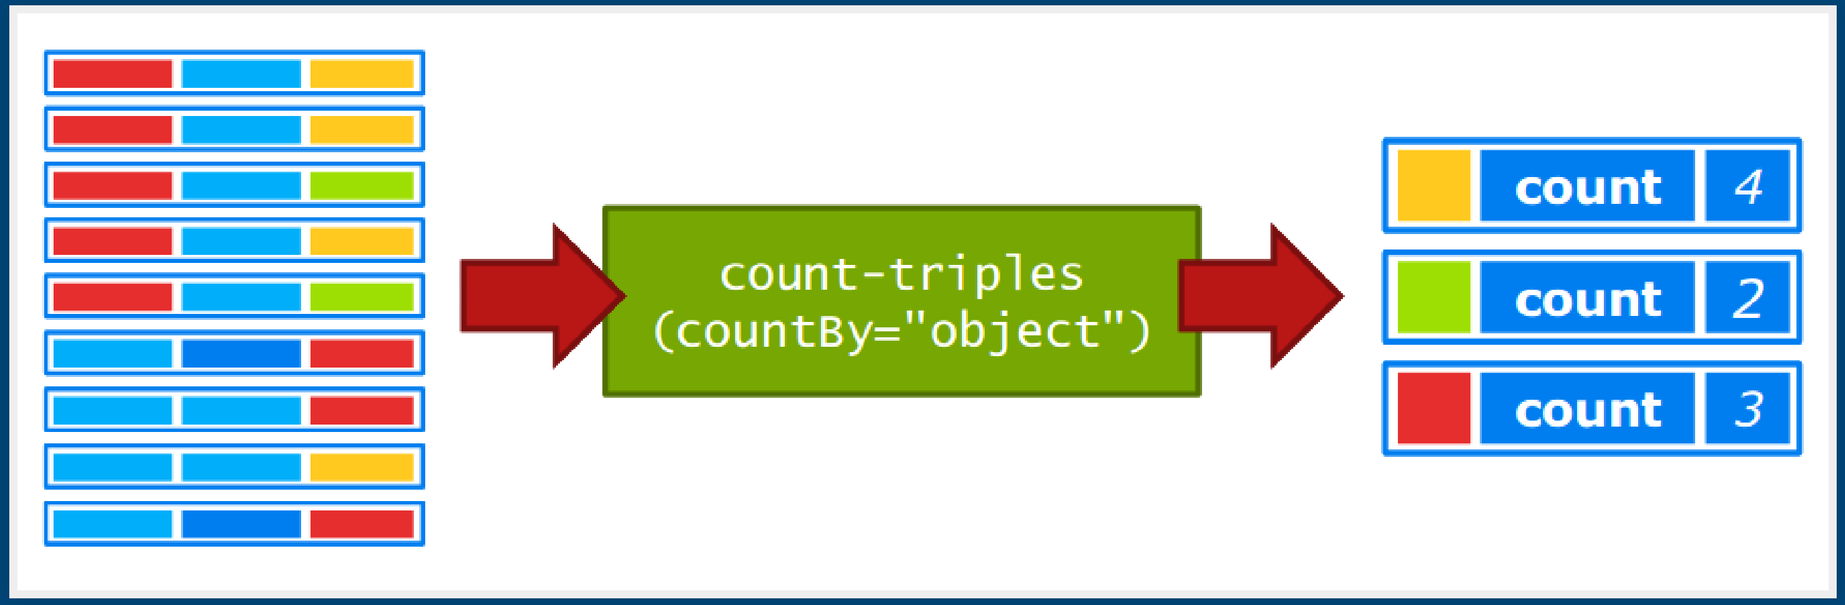

Source: Christoph Böhme, http://swib.org/swib13/slides/boehme_swib13_131.pdf

template

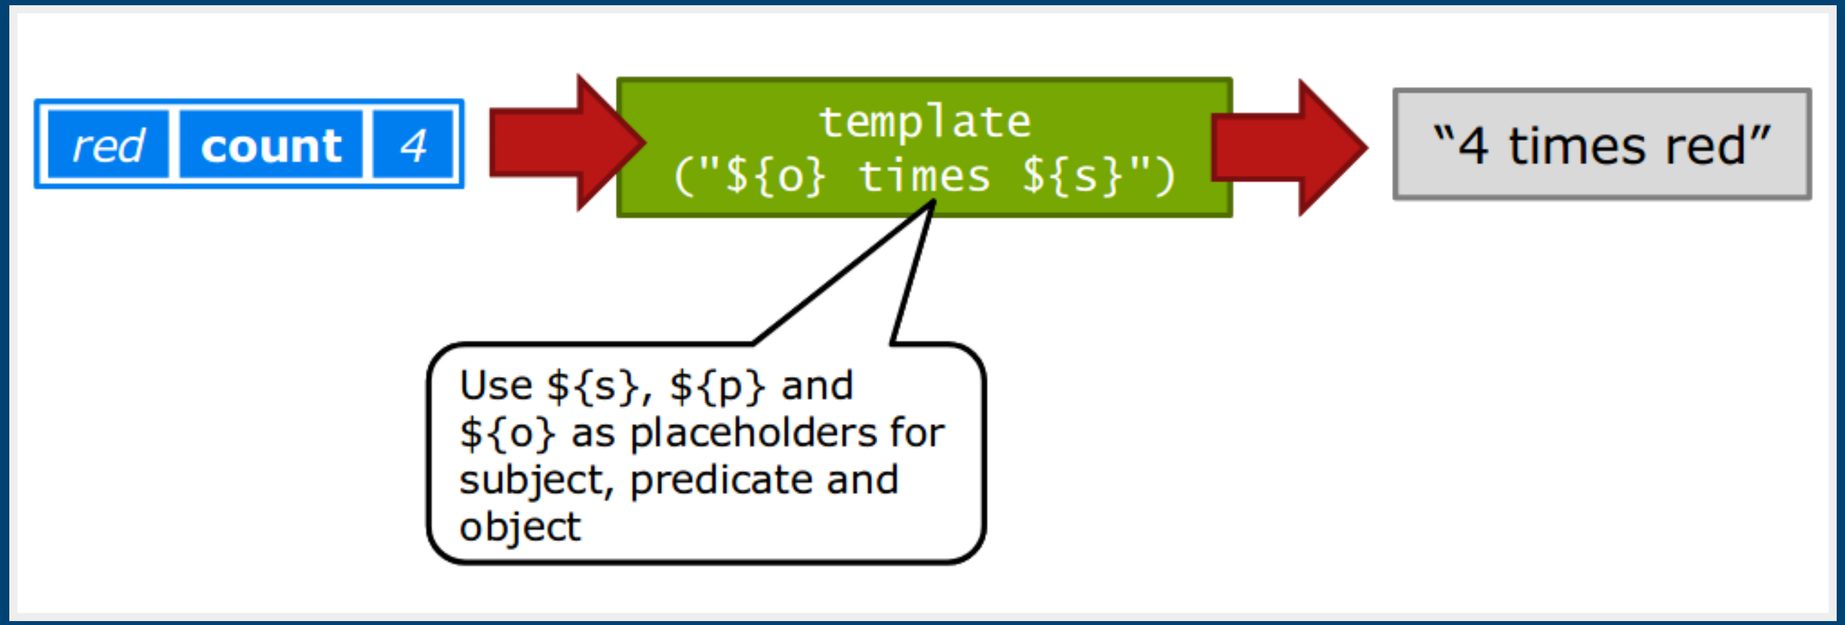

Source: Christoph Böhme, http://swib.org/swib13/slides/boehme_swib13_131.pdf

Beispiel: Feldwerte zählen

Beispiel: Feldwerte zählen

Anzahl unterschiedlicher Werte im Edition-Feld (032@.a)

Beispiel: Feldwerte zählen

Anzahl unterschiedlicher Werte im Edition-Feld (032@.a)

```
move_field('032@.a', 'Edition')
retain('Edition')
```

Beispiel: Feldwerte zählen

Anzahl unterschiedlicher Werte im Edition-Feld (032@.a)

```
move_field('032@.a', 'Edition')
retain('Edition')
```

```
PG_DATA
| as-lines
| decode-pica
| fix
| stream-to-triples
| count-triples(countBy = "object")
| template("${o} | ${s}")
| print
;
```

Load Examples | Clear | Process | Share | Import Workflow | Export Workflow

Data

```
001@ 01a5001A 09999:07-04-01001B 09999:10-03-04t13:31:00.000001D 09999:07-04-01001U 0utf8001X 00002@ 0Aal003@ 057034698
001@ 01-2a5001A 01200:28-09-87001B 09999:29-12-07t19:41:36.000001D 09999:99-99-99001U 0utf8001X 00002@ 0Aan003@ 0871159
001@ 01a5001A 09999:31-10-01001B 00101:07-08-09t17:28:39.000001D 09999:31-10-01001U 0utf8001X 00002@ 0Aal003@ 057273695
001@ a5001A 01145:29-03-04001B 01145:27-04-05t18:02:05.000001D 09999:10-05-08001U 0utf8001X 00002@ 0Acl003@ 05605684870
001@ 01-2a5001A 01130:27-10-05001B 09999:23-11-05t10:44:17.000001D 01140:03-11-05001U 0utf8001X 00002@ 0Af003@ 0976858
```

Flux

```
PG_DATA
| as-lines
| decode-pica
| fix
| stream-to-triples
| count-triples(countBy = "object")
| template("${o} | ${s}")
| print
;
```

Fix | Morph

```
move_field('032@.a', 'Edition')
retain('Edition')
```

Result

```
1|(2. Aufl.)
1|3. Aufl.
1|[6. Aufl.]
```

Daten per URL lesen

Daten per URL lesen

Statt aus Datei lesen (oder PG_DATA) auch per URL möglich

Daten per URL lesen

Statt aus Datei lesen (oder PG_DATA) auch per URL möglich

Statt `"some.file" | open-file ...` → `"http://..." | open-http`

Daten per URL lesen

Statt aus Datei lesen (oder PG_DATA) auch per URL möglich

Statt `"some.file" | open-file ...` → `"http://..." | open-http`

Aufgabe: voriges Beispiel, aber von URL lesen, was fällt auf?

Daten per URL lesen

Statt aus Datei lesen (oder PG_DATA) auch per URL möglich

Statt `"some.file" | open-file ...` → `"http://..." | open-http`

Aufgabe: voriges Beispiel, aber von URL lesen, was fällt auf?

`https://github.com/hbz/metafacture-flux-examples/blob/master/sample4/bib-data-1k.pica?raw=true`

Flux

```
"https://github.com/hbz/metafacture-flux-examples/blob/master/sample4/bib-data-1k.pica?raw=true"
| open-http
| as-lines
| decode-pica
| fix
| stream-to-triples
| count-triples(countBy = "object")
| template("${o} | ${s}")
| print;
```

Fix | Morph

```
move_field('032@.a', 'Edition')
retain('Edition')
```

Result

```
1|(16.-20. Taus.)
1|(Ausg. für die Volkswirtschaft), 3. Ausg., Stand der Unterlagen: 1981
1|(Versión rev.), 4. ed.
52|1. Aufl.
1|1. Aufl. d. Neuübers.
```

Beispiel: Feldwerte zählen

```
1 | (1. Aufl.)
1 | (16.-20. Taus.)
2 | (2. Aufl.)
1 | (2. Aufl.) - 1:10 000
1 | (2. ed.)
1 | (3. rev. ed.)
1 | (Ausg. 1971/72)
1 | (Ausg. für die Volkswirtschaft), 1. Ausg., Stand der
Unterlagen: 1977
1 | (Ausg. für die Volkswirtschaft), 1. Ausg., Stand der
Unterlagen: 1986
1 | (Ausg. für die Volkswirtschaft), 1. Ausg., Stand der
Unterlagen: 1987
1 | (Ausg. für die Volkswirtschaft), 3. Ausg., Stand der
Unterlagen: 1980
```

https://github.com/hbz/metafacture-flux-examples/tree/master/sample4

Übung: Muster zählen

Übung: Muster zählen

Ausgabe der Anzahl von Geburtsjahren (060R.a) der Muster 'yyyy' oder 'dd.mm.yyyy'

Übung: Muster zählen

Ausgabe der Anzahl von Geburtsjahren (060R.a) der Muster 'yyyy' oder 'dd.mm.yyyy'

Ausgabe der Anzahl der Werte in 060R.a, die beiden Mustern nicht entsprechen (Fehler)

Übung: Muster zählen

Ausgabe der Anzahl von Geburtsjahren (060R.a) der Muster 'yyyy' oder 'dd.mm.yyyy'

Ausgabe der Anzahl der Werte in 060R.a, die beiden Mustern nicht entsprechen (Fehler)

z.B. mit if, elsif, any_match, move_field, s. Dokumentation

Flux

```
PG_DATA
| as-lines
| decode-pica
| fix
| stream-to-triples
| count-triples(countBy="predicate")
| template("${s}:\t ${o}")
| print;
```

Fix | Morph

```
if any_match('060R.a', '^\\d{2}\\.\\d{2}.\\d{4}')
  move_field('060R.a', 'birth (full)')
elsif any_match('060R.a', '^\\d{2,4}')
  move_field('060R.a', 'birth (year)')
else
  move_field('060R.a', 'invalid birth')
end
retain('birth (full)', 'birth (year)', 'invalid birth')

```

Result

```
birth (year):    4
invalid birth:   1
```

Übung: was / warum invalid?

Übung: was / warum invalid?

1. nur 'invalid birth' retainen

Übung: was / warum invalid?

1. nur 'invalid birth' retainen
2. nicht zählen, Tripel nur ausgeben

Übung: volles Datenset per URL

Übung: volles Datenset per URL

Aufgabe: voriges Beispiel, aber von URL lesen:

Übung: volles Datenset per URL

Aufgabe: voriges Beispiel, aber von URL lesen:

`https://github.com/hbz/metafacture-flux-examples/blob/master/sample5/authority-data-1k.pica?raw=true`

Muster zählen, volle Daten, und Sterbejahre (060R.b)

```
birth (full):    873
birth (year):    4874
death (full):    460
death (year):    1587
invalid birth:   9
invalid death:   5
```

https://github.com/hbz/metafacture-flux-examples/tree/master/sample5

5. Zusammenführen

Wurmloch

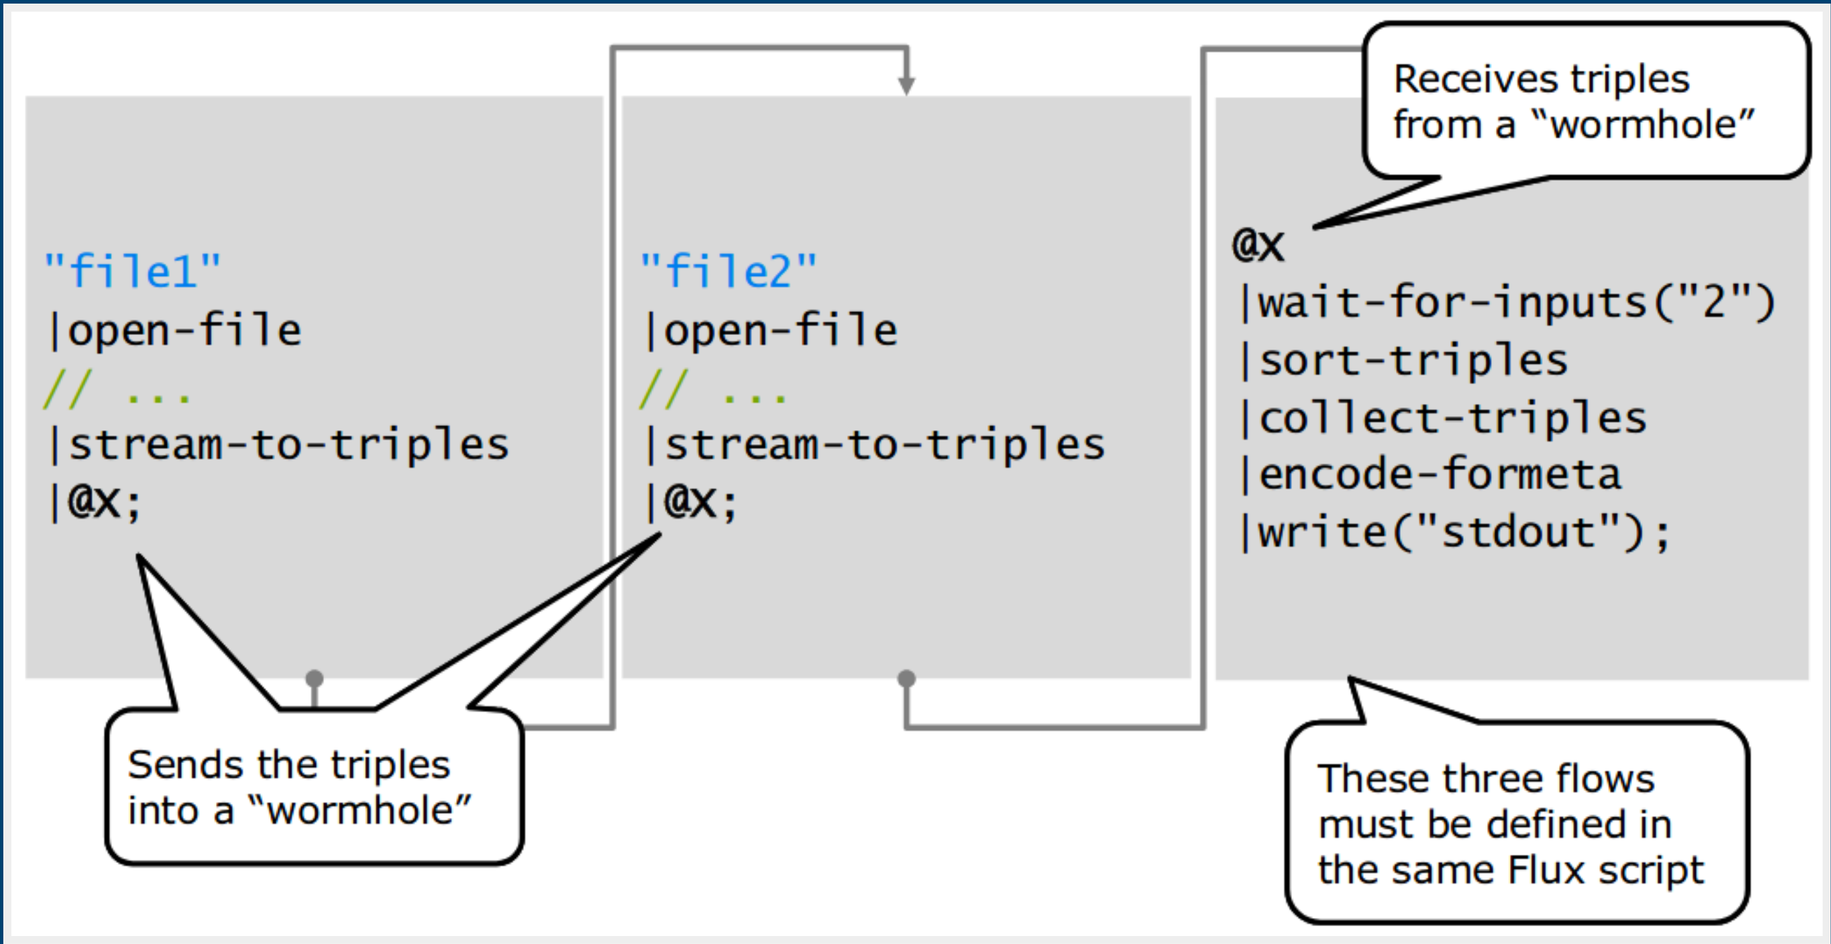

Aus: Christoph Böhme, http://swib.org/swib13/slides/boehme_swib13_131.pdf

Unterschiedliche IDs

Unterschiedliche IDs

Typischerweise haben Entitäten in unterschiedlichen Datenquellen unterschiedliche IDs

Unterschiedliche IDs

Typischerweise haben Entitäten in unterschiedlichen Datenquellen unterschiedliche IDs

z.B. GND mit GND-ID, Wikipedia mit eigener ID, aber z.B. GND-ID in Feld 'gnd'

Unterschiedliche IDs

Typischerweise haben Entitäten in unterschiedlichen Datenquellen unterschiedliche IDs

z.B. GND mit GND-ID, Wikipedia mit eigener ID, aber z.B. GND-ID in Feld 'gnd'

d.h. zum Zusammenführen brauchen wir einen Weg, die IDs aus einer der Datenquellen zu setzen

redirect="true"

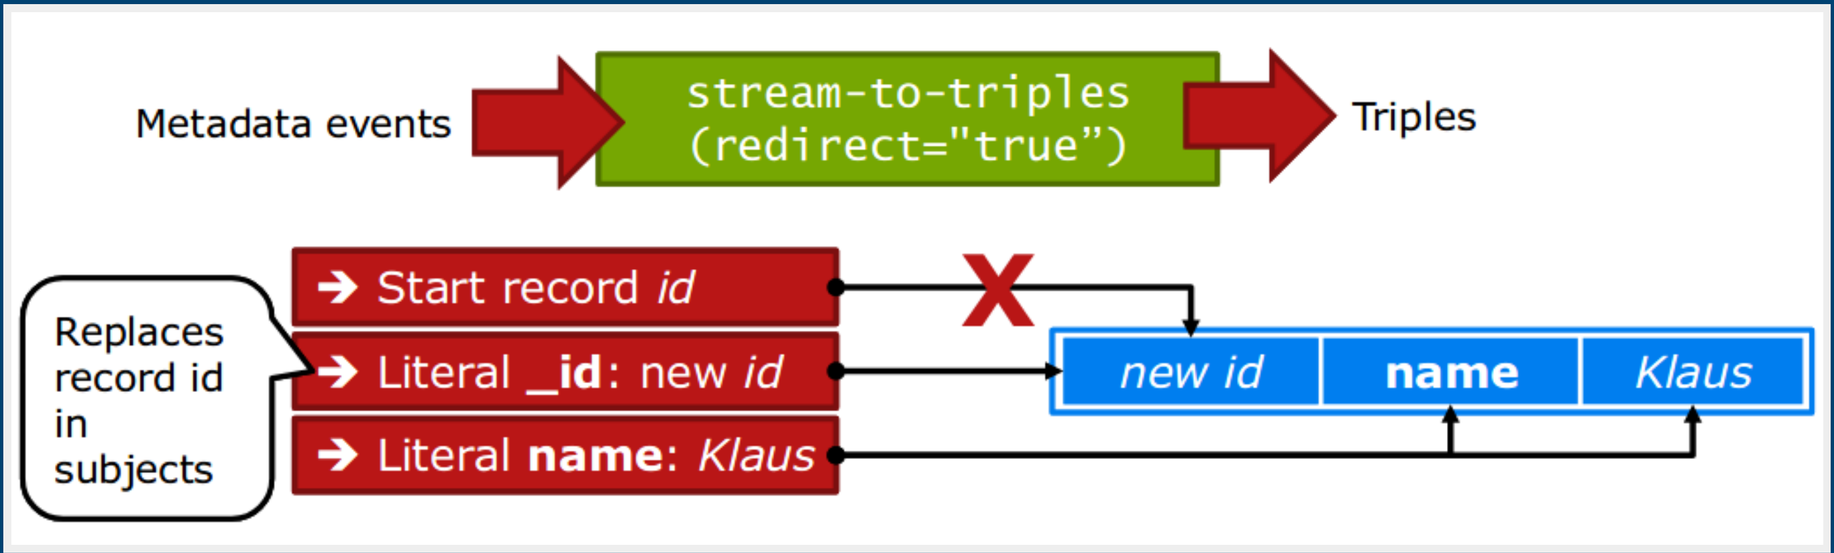

Source: Christoph Böhme, http://swib.org/swib13/slides/boehme_swib13_131.pdf

Übung: Zusammenführen / Anreichern

Wir kombinieren GND-PICA-Daten (in PG_DATA) mit Daten in wiki-persons.foma (enthalten GND-IDs im Feld 'gnd')

https://github.com/hbz/metafacture-flux-examples/tree/master/sample6

Flux

```
PG_DATA
| as-lines
| decode-pica
| stream-to-triples
| @X;

"https://raw.githubusercontent.com/hbz/metafacture-flux-examples/master/sample6/wiki-persons.foma"
| open-http
| as-lines
| decode-formeta
| fix
| stream-to-triples(redirect="true")
| @X;

@X
| wait-for-inputs("2")
| sort-triples(by="subject")
| collect-triples
| encode-json(prettyPrinting="true")
| print;
```

Fix | Morph

```
copy_field('gnd', '_id')
```

Daten zusammenführen

```
'118514768' {
        '001A' {
                 '0': '1250:01-07-88'
        },
        '001B' {
                 '0': '1140:26-07-13',
                 't': '08:58:08.000'
        },
        '001D' {
                 '0': '1220:16-06-08'
        },
        '001U' {
                 '0': 'utf8'
        },
        '001X' {
                 '0': '0'
```

https://github.com/hbz/metafacture-flux-examples/tree/master/sample6

Mit Fix wie im Abschnitt zur Transformation zu einheitlichen Datensätzen zusammenführen

Aktueller Stand Fix

Aktueller Stand Fix

Beispiele: produktiv in OERSI (diverse Web-Quellen → JSON),
im Aufbau für hbz-Verbundkatalog (MARC → JSON) und
Rheinland-Pfälzische Bibliographie (Allegro → JSON)

Aktueller Stand Fix

Beispiele: produktiv in OERSI (diverse Web-Quellen → JSON), im Aufbau für hbz-Verbundkatalog (MARC → JSON) und Rheinland-Pfälzische Bibliographie (Allegro → JSON)

Tests: unit (Simulation von Input-Output-Events und Fix auf Code-Ebene; aktuell pass 422 / 447), integration (Input, Flux, Fix, Output als Dateien wie bei Real-World-Setup; aktuell pass 170 / 228, d.h. aktuell 75% "conformance")

Aktueller Stand Fix

Beispiele: produktiv in OERSI (diverse Web-Quellen → JSON), im Aufbau für hbz-Verbundkatalog (MARC → JSON) und Rheinland-Pfälzische Bibliographie (Allegro → JSON)

Tests: unit (Simulation von Input-Output-Events und Fix auf Code-Ebene; aktuell pass 422 / 447), integration (Input, Flux, Fix, Output als Dateien wie bei Real-World-Setup; aktuell pass 170 / 228, d.h. aktuell 75% "conformance")

d.h. vieles geht schon, aber es gibt auch noch einiges zu tun

Aktueller Stand Fix

Beispiele: produktiv in OERSI (diverse Web-Quellen → JSON), im Aufbau für hbz-Verbundkatalog (MARC → JSON) und Rheinland-Pfälzische Bibliographie (Allegro → JSON)

Tests: unit (Simulation von Input-Output-Events und Fix auf Code-Ebene; aktuell pass 422 / 447), integration (Input, Flux, Fix, Output als Dateien wie bei Real-World-Setup; aktuell pass 170 / 228, d.h. aktuell 75% "conformance")

d.h. vieles geht schon, aber es gibt auch noch einiges zu tun

Aktuelle Dokumentation, GitHub-Repo, Playground

7. Ausblick, Fragen & Diskussion

Ausblick

Fix & Playground weiterentwickeln

Fix & Playground weiterentwickeln

Fix-Funktionalität erweitern, Fehler beheben, Catmandu-Kompatibilität erhöhen

F

Fix & Playground weiterentwickeln

Fix-Funktionalität erweitern, Fehler beheben, Catmandu-Kompatibilität erhöhen

Playground weiter verbessern, z.B. mehr Hinweise im Editor, integrierte Dokumentation (was gibt es für Module, wie kann ich sie kombinieren)

Standards nutzen und aufbauen

Standards nutzen und aufbauen

SKOS Lookups (zum Andocken an SkoHub Vocabs)

Standards nutzen und aufbauen

SKOS Lookups (zum Andocken an SkoHub Vocabs)

Entity Reconciliation mit OpenRefine-kompatiblen Diensten

Standards nutzen und aufbauen

SKOS Lookups (zum Andocken an SkoHub Vocabs)

Entity Reconciliation mit OpenRefine-kompatiblen Diensten

Fix-Standardisierung, s. https://github.com/elag/FIG

ETL Hub

ETL Hub

ETL: Extract, Transform, Load

ETL Hub

ETL: Extract, Transform, Load

mehr Kollaboration, Teilen & Auffinden von Workflows ermöglichen (nicht nur für Metafacture)

ETL Hub

ETL: Extract, Transform, Load

mehr Kollaboration, Teilen & Auffinden von Workflows ermöglichen (nicht nur für Metafacture)

Entwicklung von Best Practices zur Paketierung und Beschreibung von ETL-Konfigurationen

ETL Hub

ETL: Extract, Transform, Load

mehr Kollaboration, Teilen & Auffinden von Workflows ermöglichen (nicht nur für Metafacture)

Entwicklung von Best Practices zur Paketierung und Beschreibung von ETL-Konfigurationen

Aufbau eines ETL Hubs zum Entdecken existierender ETL-Prozesse für die einfache Nachnutzung und Anpassung

Fragen und Diskussion

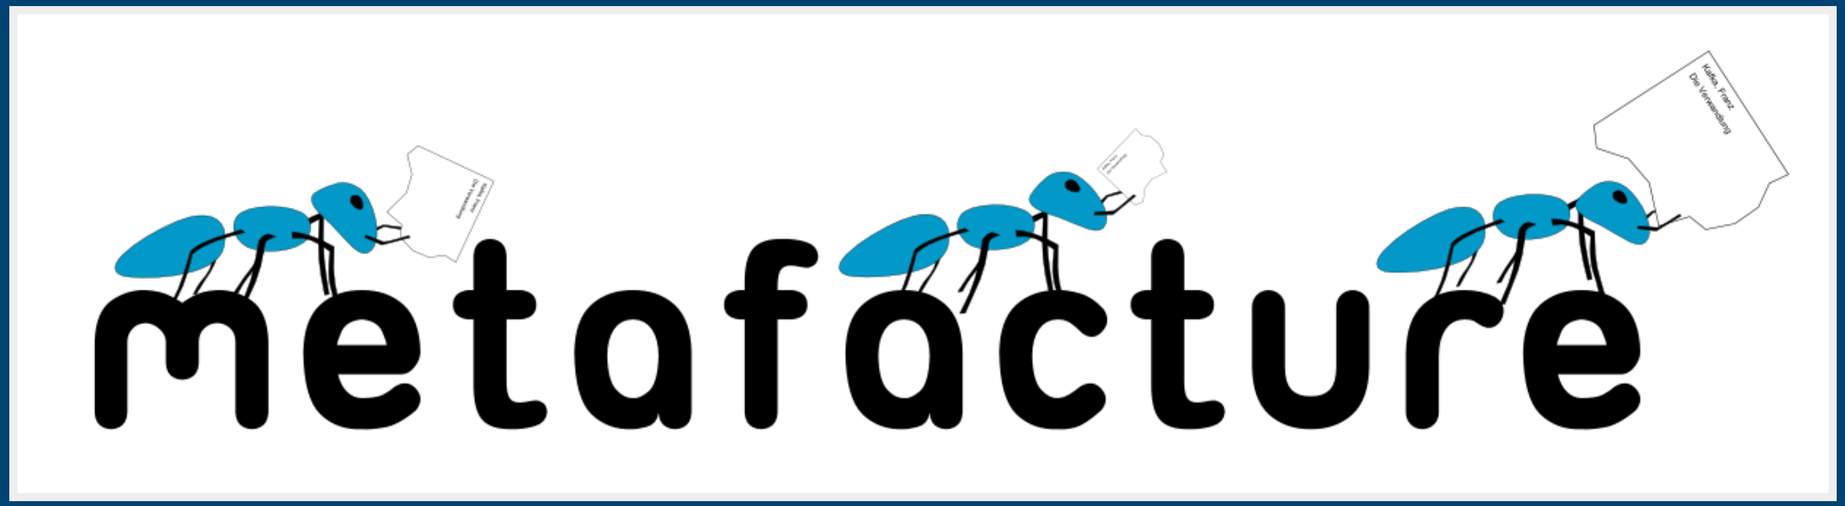

https://metafacture.org

*